

Utilisation du Machine Learning pour la Détection Précoce des AVC à partir de Données Médicales

DEPUSSAY Mathias - YILMAZ Ilayda

29 April 2025



{Image libre de droits.}

Table des matières

1	Introduction	3
2	Présentation de la base de données	3
2.1	Traitement des valeurs manquantes	3
3	Analyse descriptive	4
3.1	Variables qualitatives	4
3.2	Variables quantitatives	6
4	Préparation des données	7
4.1	Gestion de Colinéarité	7
4.2	Choix des métriques et optimisation des hyperparamètres	7
5	Modèles	9
5.1	LDA	9
5.2	LOGIT	11
5.3	KNN	13
5.4	SVM Linéaire	15
5.5	SVM Radial	17
5.6	ARBRE CART	19
5.7	FORET ALÉATOIRE	21
5.8	BOOSTING	23
6	Modèle Retenu	25
7	Conclusion	26

1 Introduction

Dans le domaine médical, la prévention des accidents vasculaires cérébraux (AVC) est un enjeu majeur de santé publique. L'AVC est l'une des principales causes de décès et d'invalidité dans le monde, avec des conséquences lourdes tant pour les patients que pour les systèmes de santé. Détecter les individus à risque permettrait d'agir en amont, d'améliorer la prise en charge et de réduire la mortalité associée.

L'objectif principal de ce projet est de développer un modèle de Machine Learning capable de prédire la survenue d'un AVC en fonction des facteurs médicaux et socio-démographiques des patients.

En identifiant les individus présentant un risque élevé, les professionnels de santé pourront mettre en place des stratégies préventives personnalisées, ce qui pourrait améliorer la prise en charge et réduire le nombre d'AVC évitables.

2 Présentation de la base de données

Notre base de données se nomme "Healthcare Stroke Dataset". Elle se compose de 11 variables et de 5110 observations, encodées sous différentes formes : numérique (numeric), binaire (0/1) et catégorielle (factor).

Cependant, certaines variables comportaient des valeurs manquantes, notamment pour l'indice de masse corporelle (bmi) et le statut tabagique (smoking_status), qui ont été traitées par imputation Bagging afin de préserver la qualité des données.

Voici une représentation des principales variables de notre dataset. Elles décrivent le genre, l'âge, les antécédents médicaux (hypertension, maladies cardiaques), les habitudes de vie (tabagisme, type de travail, résidence), ainsi que les indicateurs physiologiques comme le taux de glucose moyen et l'IMC.

TABLE 1: Variables de la base de données

Nom de la Variable	Type de Variable	Description
gender	factor	Sexe de l'individu
age	numeric	Âge
hypertension	factor	0 si le patient n'a pas d'hypertension, sinon 1
heart_disease	factor	0 si le patient n'a pas de maladies cardiaques, sinon 1
ever_married	factor	jamais marié : Non ou Oui
work_type	factor	enfants, Govt_jov, Jamais_travaillé, Privé ou Travailleur indépendant
Residence_type	factor	Lieu de résidence (Urban ou Rural)
avg_glucose_level	numeric	taux moyen de glucose dans le sang
bmi	numeric	Indice de masse corporelle (IMC)
smoking_status	factor	Statut tabagique : précédemment fumé, jamais fumé, fume ou Inconnu
stroke	factor	Indique si l'individu a eu un AVC (1 = Oui, 0 = Non)

2.1 Traitement des valeurs manquantes

Le jeu de données contient des valeurs manquantes, notamment dans la variable **bmi** (indice de masse corporelle) ainsi que dans **smoking_status**, où la modalité "unknown" est considérée comme une valeur manquante implicite.

Afin d'éviter toute fuite d'information et de garantir la reproductibilité, le traitement des valeurs manquantes est effectué au sein de la recette de prétraitement, en utilisant la fonction **step_impute_bag** du package **recipes**.

Cette méthode d'imputation repose sur des arbres en bagging, qui permettent de prédire les valeurs manquantes à partir des autres variables disponibles, de manière plus flexible et robuste que des méthodes simples comme la moyenne ou la médiane. De plus, elle prend en charge à la fois les variables numériques et catégorielles sans nécessiter de traitement différencié.

Ce choix permet :

- de garder la structure des données intacte sans perte d'information
- d'intégrer l'imputation directement dans la chaîne de modélisation
- de limiter les biais liés à l'imputation hors recette, notamment en cas de validation croisée.

3 Analyse descriptive

3.1 Variables qualitatives




FIGURE 1 – Répartition de la variable Stroke

On observe un fort déséquilibre dans la variable *stroke*, la majorité des observations prennent la modalité 0, indiquant ainsi l'absence d'AVC. Cependant, ce déséquilibre de classe peut poser des problèmes lors de l'utilisation de méthodes prédictives. En effet, il risque d'entraîner un sur-ajustement en faveur de la classe majoritaire, réduisant ainsi la capacité du modèle à bien prédire la classe minoritaire, ce qui affecterait ses performances globales.

Par la suite, nous avons réalisé plusieurs graphiques des variables qualitatives en fonction de la variable à prédire *stroke*. Ces visualisations mettent en évidence un déséquilibre de classe.




FIGURE 2 – Analyse des proportions

La proportion d'AVC semble similaire entre les genres Female et Male, et la catégorie Other ne contient aucun individus ayant à AVC.

Les individus ayant de l'hypertension ou des antécédents de maladies cardiaques semblent avoir une proportion plus élevée d'AVC que ceux qui n'en ont pas, suggérant une corrélation entre ces facteurs et les AVC.

Les individus mariés semblent être plus nombreux à avoir subi un AVC, mais cela pourrait être lié à l'âge, car les personnes mariées sont généralement plus âgées.

La répartition des AVC varie selon le type de travail, mais il semble que certaines catégories (ex. Private, Self-employed) aient une proportion légèrement plus importante de cas d'AVC.

Aucune différence marquante n'est visible entre les zones urbaines et rurales, la proportion de cas d'AVC semble être similaire.

Il semble que les fumeurs et anciens fumeurs aient une proportion d'AVC plus élevée que les personnes n'ayant jamais fumé, ce qui pourrait indiquer une influence du tabagisme sur le risque d'AVC.

D'après les résultats observés, nous supposons que certaines variables catégorielles sont dépendantes de la variable à prédire *stroke*. Pour vérifier cette hypothèse, nous allons effectuer un test du **Chi-2** afin de déterminer si ces variables sont indépendantes ou non de l'occurrence d'un AVC.

Les hypothèses du test sont définies comme suit :

- **Hypothèse nulle (H0)** : La variable étudiée est indépendante de la variable *stroke*, c'est-à-dire qu'il n'existe pas de relation statistiquement significative entre elles.
- **Hypothèse alternative (H1)** : La variable étudiée est dépendante de *stroke*, indiquant ainsi une association significative entre les deux.

Nous allons ainsi appliquer ce test à chaque variable catégorielle pour identifier celles qui pourraient avoir un lien avec la variable à prédire *stroke*.

TABLE 2: Test du χ^2

Variable	X_squared	p_value
gender	0.473	7.9e-01
Residence_type	1.082	2.98e-01
smoking_status	29.147	2.09e-06
work_type	49.164	5.4e-10
ever_married	58.924	1.64e-14
hypertension	81.605	1.66e-19
heart_disease	90.260	2.09e-21

On observe que certaines variables présentent des p-values très faibles (< 0.05), indiquant une relation statistiquement significative avec *stroke*. C'est notamment le cas de **l'hypertension, des maladies cardiaques, du statut marital, du type de travail et du statut tabagique**. Ces variables sont donc probablement associées à la variable *stroke*.

En revanche, **le genre et le type de résidence** ont des p-values élevées (> 0.05), ce qui suggère qu'elles ne sont pas significativement liées à la variable *stroke*. Cela signifie que ces variables ne semblent pas influencer de manière notable la probabilité d'avoir ou non un AVC selon notre base de données.

3.2 Variables quantitatives

Le test de Student est une méthode statistique permettant de comparer les moyennes de deux groupes afin de déterminer s'il existe une différence significative entre eux. Dans notre cas, nous utilisons ce test pour comparer les moyennes des variables quantitatives en fonction de la variable *stroke*.

- **Hypothèse nulle (H0)** : Il n'y a pas de différence significative entre les moyennes des deux groupes
- **Hypothèse alternative (H1)** : Il existe une différence significative entre les moyennes des deux groupes.

Si la p-value obtenue est inférieure à 0.05, alors on **rejette H0** et on considère qu'il existe une différence statistiquement significative entre les groupes.

TABLE 3: Test de student

Variable	t_statistic	p_value
bmi	-3.640	3.34e-04
avg_glucose_level	-6.982	2.40e-11
age	-29.686	2.12e-95

L'âge et le taux de glucose moyen sont fortement liés à la survenue d'un AVC (p-values extrêmement faibles). **L'IMC** (bmi) a un effet plus modéré, mais reste significatif.

Ces résultats suggèrent que les individus ayant un âge avancé et un taux de glucose élevé pourraient être des facteurs de risque majeurs d'AVC.

Ces résultats confirment les tendances médicales observées : les AVC sont plus fréquents chez les personnes âgées et celles ayant des niveaux de glucose élevés.

4 Préparation des données

4.1 Gestion de Colinéarité

Nous allons effectuer une analyse en composantes principales (ACP) afin de visualiser les corrélations entre les différentes variables quantitatives.




FIGURE 3 – Corrélations entre l'axe1 et l'axe2

Le cercle des corrélations met en évidence que les variables *age* et *bmi* sont fortement corrélées avec la première composante principale, tandis que *avg_glucose_level* est principalement corrélée avec la deuxième. Les trois variables sont bien représentées sur le plan factoriel, ce qui indique une bonne qualité d'information capturée par les deux premières dimensions.

4.2 Choix des métriques et optimisation des hyperparamètres

Pour corriger le déséquilibre de la variable *stroke*, qui impacte les performances du modèle, nous avons utilisé l'algorithme SMOTE-NC, adapté aux données comportant des variables catégorielles. Il a été appliqué via la fonction `step_smotenc` du package *themis*, avec deux paramètres clés :

- `over_ratio` : proportion d'individus synthétiques à générer par rapport à la classe majoritaire.
- `neighbors` : nombre de voisins de la même classe utilisés pour créer ces nouveaux individus.

Tout au long de cette étude, notre objectif a été de concevoir un modèle de machine learning capable de repérer efficacement les individus à risque d'AVC, c'est-à-dire la classe positive *stroke* = 1. Dans ce cadre, **la sensibilité** est la métrique la plus critique, car elle mesure la capacité du modèle à ne pas rater de cas positifs. Nous avons évalué les performances à l'aide d'un ensemble de métriques complémentaires : l'AUC, l'accuracy, la précision, la sensibilité et le F-measure, qui synthétise l'équilibre entre précision et rappel.

La sensibilité est définie comme la proportion d'AVC correctement identifiés parmi tous les AVC présents dans les données.

$$\text{Sensibilité} = \frac{VP}{VP + FN}$$

Même si certains modèles optimisés selon la précision ou l'AUC montrent de bons résultats, celui basé sur **la sensibilité** a été retenu, car il permet de détecter des cas d'AVC. Ce choix est justifié par notre problématique. Dans un contexte médical, il est préférable de générer plus de faux positifs que de manquer des cas réels, ce qui pourrait entraîner des conséquences graves.

L'AUC est la surface sous la courbe ROC. Elle représente la capacité du modèle à distinguer correctement entre les classes positives et négatives, indépendamment du seuil de classification.

- Une **AUC = 0.5** signifie que le modèle est aussi bon qu'un tirage aléatoire.
- Une **AUC = 1** indique une séparation parfaite entre les classes.

La courbe ROC trace le taux de vrais positifs (sensibilité) en fonction du taux de faux positifs (1 - spécificité) pour différents seuils de décision. Ainsi, plus l'AUC est proche de 1, meilleure est la capacité du modèle à discriminer les classes, ce qui est particulièrement utile dans le cas de classes déséquilibrées, comme dans notre étude.

Voici la structure standard d'une matrice de confusion pour un problème de classification binaire :

TABLE 4: Matrice de confusion

.	Réalité.0	Réalité.1
Prédit 0	vrai négatif	faux négatif
Prédit 1	faux positif	vrai positif

La matrice de confusion permet de comparer les prédictions du modèle avec la réalité. Elle met en évidence quatre types de résultats :

- **VP** : le modèle prédit **stroke = 1** AVC et l'individu a effectivement eu un AVC.
- **FP** : Le modèle prédit **stroke = 1** AVC, mais l'individu n'a pas eu d'AVC.
- **FN** : Le modèle prédit **stroke = 0**, mais l'individu a eu un AVC.
- **VN** : le modèle prédit **stroke = 0**, l'individu n'a effectivement pas eu d'AVC.

Analyser la matrice de confusion est fondamental, car elle permet de visualiser le type d'erreurs commises par le modèle. Dans un contexte médical comme le nôtre, minimiser les faux négatifs (FN) est une priorité.


Ainsi, bien que l'accuracy puisse être élevée (surtout si la classe 0 est majoritaire), elle peut masquer une mauvaise performance sur la classe minoritaire. C'est pourquoi des métriques comme la sensibilité, la précision, ou encore l'aire sous la courbe Roc sont indispensables pour évaluer la performance réelle du modèle.

5 Modèles

5.1 LDA

Le premier modèle testé est une **Analyse Discriminante Linéaire**, une méthode linéaire de classification qui suppose une distribution normale des variables explicatives dans chaque classe et une matrice de covariance commune.

La préparation des données a été réalisée à l'aide d'une recette adaptée au modèle LDA. Les valeurs "unknown" de la variable `smoking_status` ont été traitées comme manquantes, puis imputées avec la méthode `step_impute_bag()`, sans inclure la variable cible `stroke`, afin d'éviter toute fuite d'information. Les variables catégorielles ont été converties en indicatrices (`step_dummy()`), et les variables numériques ont été centrées et réduites pour répondre aux exigences du modèle. Enfin, un sur-échantillonnage SMOTE-NC a été appliqué via `step_smotenc()` pour corriger le déséquilibre de classes, avec une optimisation des paramètres `over_ratio` et `neighbors` par validation croisée.



Nous avons choisi d'optimiser le modèle en fonction de la **précision**, car cette métrique permettait d'obtenir la meilleure valeur de spécificité, en réduisant efficacement le nombre de faux positifs. Ce choix conduit à la sélection des paramètres optimaux suivants pour la méthode SMOTE-NC : un `over_ratio` de 1 et un nombre de voisins égal à 3.

Ci-dessous, nous présentons la matrice de confusion obtenue avec **le modèle LDA**. Le modèle parvient à identifier 63 individus ayant réellement fait un AVC, et à reconnaître 1174 individus n'en ayant pas fait. En revanche, 14 cas d'AVC n'ont pas été détectés, ce qui constitue une erreur importante dans un contexte médical, puisqu'un individu à risque n'est pas identifié. De plus, 453 individus ont été faussement classés comme ayant fait un AVC, ce qui représente un nombre conséquent de fausses alertes.

Dans un contexte fortement déséquilibré, comme ici, **la sensibilité**, qui mesure la capacité du modèle à détecter les cas positifs, est une métrique bien plus pertinente que l'accuracy. Dans notre cas, la sensibilité atteint **81.82%**, ce qui indique que le modèle parvient à détecter une grande majorité des personnes ayant réellement fait un AVC.

TABLE 5: Matrice de confusion : LDA

Prédit	Réalité.0	Réalité.1	Total
0	1174	14	1188
1	453	63	516
Total	1627	77	1704




TABLE 6 : Récapitulatif des performances : LDA

Métrique	X.
Précision	12.21
Sensibilité	81.82
Spécificité	72.16
Taux de faux positifs	27.84
Taux de faux négatifs	18.18
Accuracy	72.59
F-score	21.25
AUC	83.99


Le modèle LDA atteint une aire sous la courbe ROC de **83.99%**, ce qui témoigne d'une bonne capacité de discrimination entre les individus ayant fait un AVC et ceux qui n'en ont pas fait. Cela reflète donc une performance globalement satisfaisante.

Le tableau récapitulatif met également en lumière plusieurs éléments importants. D'une part, la sensibilité élevée **81.82%** indique que le modèle parvient à détecter la grande majorité des cas d'AVC, ce qui est essentiel dans un contexte médical. En revanche, la précision relativement faible **12.21%** montre qu'un grand nombre de prédictions positives sont en réalité des faux positifs. Ce compromis est assumé dans notre approche : il vaut mieux générer plus de fausses alertes que de manquer un cas réel. Enfin, les autres métriques comme la spécificité **72.16%** et le F-score **21.25%** confirment cette orientation stratégique, centrée sur la détection de la classe minoritaire au détriment d'une précision parfaite.

5.2 LOGIT

Le second modèle testé est une **régression logistique**, une méthode de classification linéaire adaptée à une variable réponse binaire. Elle permet de modéliser la probabilité qu'un événement se produise, ici la survenue d'un AVC, en fonction de variables explicatives. L'un des avantages de ce modèle est l'interprétabilité directe des coefficients : un coefficient positif indique une augmentation de la probabilité d'AVC, et un coefficient négatif une diminution.

Le modèle logit a été entraîné à partir de données prétraitées selon une recette standardisée : les modalités "unknown" de **smoking_status** ont été traitées comme des valeurs manquantes, puis imputées sans inclure la variable cible stroke. Les variables ont ensuite été transformées (encodage, normalisation), et un sur-échantillonnage **SMOTE-NC** a été appliqué, avec optimisation des paramètres **over_ratio** et **neighbors** par validation croisée.



Nous avons choisi d'optimiser le modèle en fonction de la **sensibilité**, car cette métrique permettait de maximiser la détection des cas d'AVC, en réduisant le nombre de faux négatifs. Ce choix a conduit à la sélection des paramètres optimaux suivants pour la méthode SMOTE-NC : un **over_ratio** de 0.1 et un nombre de voisins égal à 13.

La matrice de confusion ci-dessous a été obtenue avec le **modèle LOGIT**, en appliquant un **seuil de 0.1** pour mieux capter les cas d'AVC. Le modèle identifie 59 vrais positifs et 1220 vrais négatifs, mais laisse passer 18 faux négatifs, ce qui reste critique dans un contexte médical. Il génère également 407 faux positifs, soit un volume non négligeable de fausses alertes.

Dans un contexte déséquilibré comme celui-ci, la sensibilité constitue une métrique plus adaptée que l'accuracy. Ici, elle atteint **76.62%**, ce qui témoigne d'une bonne capacité du modèle à détecter les cas positifs.

TABLE 6: Matrice de confusion : LOGIT

Prédit	Réalité.0	Réalité.1	Total
0	1220	18	1238
1	407	59	466
Total	1627	77	1704

TABLE 8 : Coefficients du modèle LOGIT

Variable	Coefficient	p.value
age	2.208	2.39e-229
work_type_Private	-0.992	1.05e-10
work_type_Self.employed	-0.972	8.92e-16
work_type_Govt_job	-0.854	3.39e-15
work_type_Never_worked	-0.832	9.56e-01
smoking_status_never.smoked	-0.231	1.84e-07
avg_glucose_level	0.210	1.17e-10
gender_Other	-0.200	9.89e-01
gender_Male	-0.177	8.77e-07
hypertension_TRUE.	0.151	1.17e-07
bmi	0.114	1.21e-02
ever_married_Yes	0.076	1.92e-01
Residence_type_Urban	0.076	2.76e-02
smoking_status_smokes	-0.060	1.52e-01
smoking_status_Unknown	-0.049	3.22e-01
heart_disease_TRUE.	0.029	2.99e-01

Les variables les plus significatives sont **l'âge**, **le niveau de glucose**, **l'hypertension**, et certaines modalités de profession. L'âge et le glucose ont un effet positif sur le risque d'AVC, tandis que le fait de ne jamais avoir fumé ou d'exercer une activité professionnelle est associé à une probabilité plus faible. D'autres variables comme **gender_Other** ou **work_type_Never_worked** ne sont pas significatives.




TABLE 7 : Récapitulatif des performances : LOGIT

Métrique	X.
Précision	12.66
Sensibilité	76.62
Spécificité	74.98
Taux de faux positifs	25.02
Taux de faux négatifs	23.38
Accuracy	75.06
F-score	21.73
AUC	84.12


Le modèle LOGIT atteint une AUC de **84.12%**, traduisant une bonne capacité à distinguer les individus ayant fait un AVC de ceux qui n'en ont pas fait. Bien que sa sensibilité **76.62%** soit légèrement inférieure à celle du LDA, il compense par une meilleure précision et spécificité, ce qui reflète un compromis plus équilibré.

Dans un contexte médical, ce type de **modèle reste particulièrement utile** car il permet de limiter les faux négatifs tout en réduisant le nombre de fausses alertes. De plus, sa structure linéaire et ses coefficients interprétables facilitent l'analyse des facteurs de risque associés aux AVC.

5.3 KNN

Le troisième modèle testé est le **K plus proches voisins**, un algorithme non paramétrique qui classe un individu en fonction des étiquettes majoritaires parmi ses voisins les plus proches dans l'espace des variables explicatives. Ce modèle est particulièrement sensible à la mise à l'échelle des données et au bruit, ce qui impose un prétraitement rigoureux.

Le prétraitement des données pour le modèle KNN suit la même logique que pour les autres modèles, avec en plus un centrage et une réduction essentiels pour ce type d'algorithme basé sur la distance. Le sur-échantillonnage SMOTE-NC a également été intégré à la recette, avec une optimisation spécifique des paramètres **over_ratio** et **neighbors**.



Pour le **modèle KNN**, nous avons choisi d'optimiser la **précision**, dans le but de réduire le nombre de faux positifs. Cette approche a conduit à la sélection des paramètres optimaux suivants pour la méthode SMOTE-NC : un **over_ratio** de 1 et un nombre de voisins égal à 15

Nous présentons la matrice de confusion obtenue avec le **modèle KNN**, en appliquant un **seuil de décision de 0.1** afin d'augmenter la détection des cas d'AVC. Le modèle parvient à identifier 36 individus ayant réellement fait un AVC, et à reconnaître 1289 individus n'en ayant pas fait. En revanche, 41 cas d'AVC n'ont pas été détectés, ce qui constitue une erreur critique dans un contexte médical. De plus, 338 individus ont été faussement classés comme ayant fait un AVC, générant un volume important de fausses alertes.

Dans une situation de déséquilibre de classes, la sensibilité reste une métrique plus pertinente que l'accuracy. Ici, elle atteint **46.75%**, traduisant une capacité limitée à détecter les cas positifs.

TABLE 7: Matrice de confusion : KNN

Prédit	Réalité.0	Réalité.1	Total
0	1289	41	1330
1	338	36	374
Total	1627	77	1704




TABLE 8 : Récapitulatif des performances : KNN

Métrique	X.
Précision	9.63
Sensibilité	46.75
Spécificité	79.23
Taux de faux positifs	20.77
Taux de faux négatifs	53.25
Accuracy	77.76
F-score	15.96
AUC	65.42

Le modèle KNN atteint une AUC de **65.42%**, ce qui reflète une capacité de discrimination plus limitée entre les individus ayant fait un AVC et ceux qui n'en ont pas fait. Avec une sensibilité de **46.75%** et une précision de seulement **9.63%**, le modèle montre des difficultés à détecter efficacement les cas positifs tout en évitant les fausses alertes.


Dans un contexte médical, où la détection des cas réels est essentielle, ces performances restent **insuffisantes**. Bien que l'ajustement du seuil à 0.1 ait permis d'augmenter légèrement la sensibilité, le compromis global reste déséquilibré, avec un F-score de seulement **15.96%**. Ce modèle apparaît donc moins adapté que les approches logit ou LDA dans notre problématique.

5.4 SVM Linéaire

Le quatrième modèle testé est un **SVM linéaire** (Support Vector Machine), une méthode de classification supervisée qui cherche à déterminer l'hyperplan optimal séparant les classes, en maximisant la marge entre les observations les plus proches de chaque classe, appelées vecteurs de support.

Le modèle SVM linéaire a été entraîné à partir de données prétraitées selon une procédure similaire à celle appliquée pour le LDA. Les modalités "unknown" de **smoking_status** ont été imputées, les variables **catégorielles encodées**, et les variables numériques **normalisées** conformément aux exigences du SVM. Un sur-échantillonnage **SMOTE-NC** a permis de corriger le déséquilibre de classes, avec une optimisation conjointe des hyperparamètres **cost**, **over_ratio** et **neighbors** par validation croisée.

Le paramètre **cost** contrôle le compromis entre la complexité du modèle et la tolérance aux erreurs de classification : plus sa valeur est élevée, plus le modèle cherche à éviter les erreurs, quitte à devenir plus rigide.



Nous avons choisi d'optimiser le modèle SVM linéaire en fonction de **roc_auc**, car cette métrique permettait de maximiser la capacité du modèle à distinguer les individus ayant fait un AVC de ceux qui n'en ont pas fait. Ce choix a conduit à la sélection des paramètres optimaux suivants pour la méthode SMOTE-NC : un **over_ratio** de **1** et un nombre de voisins égal à **7**, combinés à un paramètre **cost** égal à **0.0625**.

La matrice de confusion obtenue pour le modèle **SVM linéaire**, avec un **seuil à 0.3**, montre que le modèle parvient à identifier 68 individus ayant réellement fait un AVC, tout en reconnaissant 1021 individus n'en ayant pas fait. En revanche, 9 cas d'AVC n'ont pas été détectés, ce qui reste relativement faible, tandis que 606 individus ont été faussement classés comme ayant fait un AVC, entraînant un nombre important de fausses alertes.

TABLE 8: Matrice de confusion : SVM linéaire

Prédit	Réalité.0	Réalité.1	Total
0	1021	9	1030
1	606	68	674
Total	1627	77	1704




TABLE 9 : Récapitulatif des performances : SVM linéaire

Métrique	X.
Précision	10.09
Sensibilité	88.31
Spécificité	62.75
Taux de faux positifs	37.25
Taux de faux négatifs	11.69
Accuracy	63.91
F-score	18.11
AUC	83.81


Le **modèle SVM linéaire** atteint une AUC de **83.81%**, indiquant une bonne capacité de discrimination entre les individus ayant fait un AVC et ceux qui n'en ont pas fait. Sa sensibilité élevée à **88.31%** montre une très bonne capacité à détecter les cas positifs, ce qui est essentiel dans un contexte médical. En revanche, la précision reste faible **10.09%**, en raison d'un grand nombre de faux positifs **37.25%**, ce qui limite la fiabilité des prédictions positives. Le F-score **18.11%**, relativement modeste, reflète ce compromis entre détection efficace et manque de précision.

5.5 SVM Radial

Le modèle testé est un **SVM à noyau radial**, une méthode de classification non linéaire capable de capturer des relations complexes entre les variables. Contrairement au SVM linéaire, ce modèle projette les données dans un espace de dimension plus élevée grâce au noyau RBF, ce qui permet de mieux séparer les classes lorsque les frontières ne sont pas linéaires.

Le modèle **SVM radial**, implémenté via le moteur **kernlab**, a été entraîné à partir de données préparées selon une recette standard : **imputation** des valeurs manquantes, transformation des variables **catégorielles**, et **normalisation** des variables numériques. Le déséquilibre de classes a été corrigé par **SMOTE-NC**, intégré à la recette, et l'ensemble des hyperparamètres **over_ratio**, **neighbors**, **cost** et **rbf_sigma** ont été optimisés par validation croisée.

Ici, **rbf_sigma** détermine la portée d'influence d'un point d'entraînement dans le noyau radial : une valeur élevée entraîne un modèle très localisé, tandis qu'une valeur plus faible donne une décision plus lisse et globale.



Pour le **modèle SVM à noyau radial**, nous avons choisi d'optimiser les performances selon l'aire sous la **courbe ROC**. Cette optimisation a conduit à la sélection des hyperparamètres suivants : un coût de **0.125**, un paramètre de noyau **rbf_sigma** égal à **1.259**, un **over_ratio** de **1** pour SMOTE-NC, et un nombre de voisins égal à **11**.

La matrice de confusion obtenue avec un seuil fixé à **0.1**, montre que le modèle a correctement identifié 55 individus ayant réellement fait un AVC, ainsi que 993 individus n'en ayant pas fait. En revanche, 22 cas d'AVC n'ont pas été détectés, tandis que 634 individus ont été faussement classés comme ayant fait un AVC.

TABLE 9: Matrice de confusion : SVM radial

Prédit	Réalité.0	Réalité.1	Total
0	993	22	1015
1	634	55	689
Total	1627	77	1704




TABLE 10: Récapitulatif des performances : SVM radial

Métrique	X.
Précision	7.98
Sensibilité	71.43
Spécificité	61.03
Taux de faux positifs	38.97
Taux de faux négatifs	28.57
Accuracy	61.50
F-score	14.36
AUC	69.41

Le modèle SVM radial, évalué avec un seuil de prédiction fixé à 0.1, atteint une AUC de **69.41%**, sa sensibilité de **71.43%** reflète une orientation forte vers la détection des cas positifs. Toutefois, cette stratégie se fait au prix d'une précision très faible (**7.98%**), en raison d'un taux élevé de faux positifs (**38.97%**) et un F-score de **14.36%**, relativement bas.


Bien que le modèle parvienne à identifier une part importante des cas d'AVC, ses performances globales **ne montrent aucun avantage clair** par rapport aux autres approches plus simples et plus stables testées dans cette étude.

5.6 ARBRE CART

Le modèle testé est **un arbre de décision**, une méthode non paramétrique de classification qui segmente les individus à partir de règles de décision successives sur les variables explicatives. Son principal avantage réside dans sa lisibilité et sa capacité à gérer les interactions entre variables sans transformation préalable

Lors de l'entraînement, trois paramètres ont été optimisés conjointement par validation croisée : le paramètre **cost_complexity**, qui régule la complexité de l'arbre en limitant les divisions superflues, ainsi que les paramètres **over_ratio** et **neighbors**, propres au sur-échantillonnage. Cette combinaison permet d'obtenir un arbre suffisamment expressif, tout en maîtrisant le surapprentissage et en améliorant la détection de la classe minoritaire.

Le paramètre **cost_complexity** régule la taille de l'arbre de décision en pénalisant les divisions inutiles. Une valeur plus élevée conduit à un arbre plus simple, tandis qu'une valeur faible autorise davantage de ramification, au risque de surajuster les données.




Pour le **modèle CART**, nous avons choisi d'optimiser la métrique **ROC AUC**, car c'est celle qui donnait les meilleurs résultats lors de la validation croisée. Cette approche a permis de sélectionner les paramètres optimaux suivants pour la méthode SMOTE-NC : un **over_ratio** de **0.1**, un nombre de voisins égal à **11**, ainsi qu'une valeur de **cost_complexity** très faible (**1e-5**).

La matrice de confusion du **modèle CART**, obtenue avec un **seuil de 0.1**, montre que le modèle parvient à identifier 47 individus ayant réellement fait un AVC, et à reconnaître 1326 individus n'en ayant pas fait. En revanche, 30 cas d'AVC n'ont pas été détectés, ce qui reste problématique dans un contexte médical. À l'inverse, 301 individus ont été faussement classés comme ayant fait un AVC, générant un nombre conséquent de fausses alertes.

TABLE 10: Matrice de confusion : Arbre CART

Prédit	Réalité.0	Réalité.1	Total
0	1326	30	1356
1	301	47	348
Total	1627	77	1704

Arbre de Décision CART



La variable **age** intervient très tôt dans l'arbre, indiquant son importance prédictive, suivie par les variables **avg_glucose_level**, **bmi**, **hypertension** et **smoking_status**. On observe également des sous-groupes bien définis selon le profil médical et socio-démographique des individus, ce qui rend ce modèle particulièrement interprétable et utile.




TABLE 9 : Récapitulatif des performances : Arbre CART

Métrique	X.
Précision	13.51
Sensibilité	61.04
Spécificité	81.50
Taux de faux positifs	18.50
Taux de faux négatifs	38.96
Accuracy	80.58
F-score	22.12
AUC	81.38

Le modèle CART atteint une AUC de **81.38%**, indiquant une bonne capacité à distinguer les individus ayant fait un AVC de ceux qui n'en ont pas fait. Avec une sensibilité de **61.04%**, le modèle détecte une proportion raisonnable de cas positifs, bien que près de **39%** des AVC ne soient pas identifiés (faux négatifs).

La précision reste relativement faible, ce qui signifie que de nombreuses alertes émises par le modèle concernent des individus qui n'ont en réalité pas fait d'AVC. Ce compromis entre détection et fiabilité est également reflété dans le F-score, qui reste modeste. La spécificité de **81.50%** montre que le modèle classe correctement la majorité des individus non concernés.


Ces résultats, obtenus avec un **seuil fixé à 0.1**, montrent que CART parvient à détecter **davantage** de cas que le modèle KNN, tout en restant plus lisible que d'autres approches plus complexes.

5.7 FORET ALÉATOIRE

Le modèle testé est **une forêt aléatoire** (Random Forest), une méthode d'ensemble fondée sur la combinaison de plusieurs arbres de décision, permettant de réduire la variance et d'améliorer la robustesse des prédictions.

La préparation des données suit les mêmes étapes que précédemment, avec **traitement des valeurs manquantes**, transformation des **variables catégorielles**, et **standardisation des prédictors**. Un sur-échantillonnage **SMOTE-NC** a également été appliqué pour corriger le déséquilibre de classes. Les hyperparamètres du modèle, notamment **mtry**, **min_n**, et **trees**, ont été optimisés par validation croisée, tout comme ceux du SMOTE.

Le paramètre **mtry** désigne le nombre de variables testées à chaque division d'un arbre, influençant la diversité entre les arbres. **min_n** fixe le nombre minimum d'observations dans un nœud pour qu'il soit divisé, limitant les partitions trop fines. Enfin, **trees** correspond au nombre total d'arbres construits dans le modèle.




Pour l'optimisation du modèle Random Forest, nous avons choisi d'utiliser **la sensibilité** comme métrique principale. Cette approche a conduit à la sélection des hyperparamètres suivants : un **mtry** de **5**, **162** arbres (**trees**), un **min_n** de **7**, un **over_ratio** de **0** et **3** voisins pour SMOTE-NC.

Avec **un seuil fixé à 0.05**, la matrice de confusion du modèle Random Forest montre que le modèle a correctement identifié 60 individus ayant réellement fait un AVC, et 1152 individus n'en ayant pas fait. En revanche, 17 cas d'AVC n'ont pas été détectés, tandis que 475 individus ont été faussement classés comme ayant fait un AVC.

Ce choix de seuil très bas permet de maximiser la détection des cas positifs, tout en maintenant un nombre de faux négatifs relativement faible, ce qui est essentiel dans un contexte médical.

TABLE 11: Matrice de confusion : Random Forest

Prédit	Réalité.0	Réalité.1	Total
0	1152	17	1169
1	475	60	535
Total	1627	77	1704



En analysant l'importance des variables, on observe que **avg_glucose_level** est celle qui contribue le plus aux prédictions du modèle, suivie de **age** et **bmi**. Ces trois variables semblent donc jouer un rôle majeur dans la probabilité de survenue d'un AVC, selon le modèle Random Forest.




TABLE 12: Récapitulatif des performances : Random Forest

Métrique	X.
Précision	11.21
Sensibilité	77.92
Spécificité	70.81
Taux de faux positifs	29.19
Taux de faux négatifs	22.08
Accuracy	71.13
F-score	19.61
AUC	82.24

Le modèle Random Forest, évalué avec un seuil fixé à 0.05, affiche une sensibilité de **77.92%**. Toutefois, cette stratégie s'accompagne d'une précision relativement faible (**11.21%**), liée à un taux de faux positifs de **29.19%**. Le F-score (**19.61%**) confirme ce compromis entre détection et fiabilité. Enfin, l'AUC de **82.24%** traduit une capacité de discrimination globalement satisfaisante, comparable aux meilleurs modèles testés


Le modèle présente une bonne sensibilité et une AUC solide, mais ses performances restent **légèrement inférieures** à celles du SVM linéaire, notamment en termes de précision et de F-score

5.8 BOOSTING

Le dernier modèle exploré est un **Boosting**, implémenté avec le moteur XGBoost, reconnu pour sa capacité à modéliser des interactions complexes tout en maintenant de bonnes performances sur des données déséquilibrées.

La recette de prétraitement reprend les étapes classiques appliquées aux autres modèles : **traitement des valeurs manquantes**, transformation des **variables catégorielles**, et application de SMOTE pour corriger le déséquilibre de classes. Les hyperparamètres du modèle, notamment **trees**, **min_n**, **mtry**, **tree_depth**, et **learn_rate**, ont été optimisés par validation croisée afin de maximiser les performances du modèle.

Le paramètre **tree_depth** contrôle la profondeur maximale des arbres, ce qui permet de limiter leur complexité. Quant à **learn_rate**, il régle la vitesse d'apprentissage du modèle : une valeur faible rend l'apprentissage plus progressif mais plus stable.




Pour l'optimisation du modèle de **boosting**, nous avons choisi d'utiliser **Roc_auc** comme métrique principale. Cette approche a conduit à la sélection des hyperparamètres suivants : un nombre d'arbres de **275**, une profondeur d'arbre de **5**, un taux d'apprentissage d'environ **1.00**, un min_n de **40**, un mtry de **10**, ainsi qu'un over_ratio de **0.325** et **6** voisins pour le sur-échantillonnage SMOTE.

Avec un seuil fixé à **0.05**, le modèle de boosting a correctement identifié 51 individus ayant réellement fait un AVC, et 1242 individus n'en ayant pas fait. En revanche, il a produit 26 faux négatifs et 385 faux positifs, ce qui traduit un modèle orienté vers la détection des cas positifs tout en limitant les fausses alertes comparé à d'autres modèles

TABLE 12: Matrice de confusion : Boosting

Prédit	Réalité.0	Réalité.1	Total
0	1242	26	1268
1	385	51	436
Total	1627	77	1704



L'analyse de l'importance des variables montre que **hypertension**, suivie de **l'âge** et **du sexe masculin**, sont les facteurs les plus déterminants dans la prédiction de la survenue d'un AVC par le modèle de Boosting




TABLE 13: Récapitulatif des performances : Boosting

Métrique	X.
Précision	11.70
Sensibilité	66.23
Spécificité	76.34
Taux de faux positifs	23.66
Taux de faux négatifs	33.77
Accuracy	75.88
F-score	19.88
AUC	78.22

Le modèle **Boosting** affiche des performances correctes avec une AUC de **78.22%** et une sensibilité de **66.23%**, traduisant une capacité raisonnable à détecter les cas d'AVC.

Toutefois, malgré une précision légèrement supérieure à certains autres modèles (**11.70%**), il reste **moins performant** que le SVM linéaire, qui présente un meilleur équilibre entre détection, fiabilité et capacité de discrimination.

6 Modèle Retenu

Afin de déterminer le modèle le plus adapté à notre problématique, nous avons comparé les performances de l'ensemble des modèles testés à l'aide d'un tableau récapitulatif et des courbes ROC.

L'objectif principal de cette étude étant la détection des individus à risque d'AVC, **la sensibilité** a été placée au cœur de notre démarche. Dans un contexte médical, il est préférable de générer plus de fausses alertes que de passer à côté d'un cas réel d'AVC.




TABLE 13 – Comparaison des performances des modèles

Modèle	Précision	Sensibilité	Spécificité	Faux.positifs	Faux.négatifs	Accuracy	F.score	AUC
LDA	12.21	81.82	72.16	27.84	18.18	72.59	21.25	83.99
Logit	12.66	76.62	74.98	25.02	23.38	75.06	21.73	84.12
KNN	9.63	46.75	79.23	20.77	53.25	77.76	15.96	65.42
CART	13.51	61.04	81.5	18.5	38.96	80.58	22.12	81.38
SVM Linéaire	10.09	88.31	62.75	37.25	11.69	63.91	18.11	83.81
SVM Radial	7.98	71.43	61.03	38.97	28.57	61.5	14.36	69.41
Random Forest	11.21	77.92	70.81	29.19	22.08	71.13	19.61	82.24
Boosting	11.7	66.23	76.34	23.66	33.77	75.88	19.88	78.22

Parmi les modèles testés, deux se démarquent particulièrement : **la régression logistique (Logit)** et **le SVM linéaire**. Le premier présente un bon équilibre entre précision et spécificité, tandis que le second affiche la meilleure sensibilité (88.31%) et une AUC élevée (83.81%), ce qui reflète une capacité solide de discrimination entre les classes.

7 Conclusion

Nous avons finalement retenu le modèle **SVM linéaire**, car il maximise la détection des cas d'AVC, ce qui est essentiel dans notre contexte. Malgré une précision plus faible, ce modèle permet d'identifier une large majorité des individus réellement à risque, tout en conservant de bonnes performances globales. Ce choix est également renforcé par les courbes ROC, où le SVM linéaire se positionne parmi les meilleures solutions, et par le tableau comparatif des performances où il se distingue en termes de sensibilité et d'AUC, nos critères prioritaires.

À l'opposé, le modèle **KNN** s'est révélé être le moins performant dans notre contexte. Avec une sensibilité de seulement 46.75%, il ne parvient à détecter qu'un peu moins d'un AVC sur deux, ce qui est problématique dans une approche médical. De plus, son AUC faible (65.42%) traduit une mauvaise capacité à discriminer les individus à risque, et son taux de faux négatifs élevé (53.25%) signifie qu'il laisse passer un grand nombre de cas réels. Dans un domaine où chaque cas d'AVC non détecté peut avoir des conséquences graves, ce type de modèle ne répond pas aux exigences de fiabilité attendues.